

Echantillonnage et estimation

Région Grand-Est



Maxence Champot - Maé Clément

BUT Science des Données 1

2025 – 2026

Table des matières

Introduction	3
Partie 1 : Estimation du nombre d'habitants d'une région de France	3
Contexte	3
Phase 0 : préparation du jeu de données	4
Phase 1 : vision globale	4
Phase 2 : calculer des valeurs	4
L'échantillonnage aléatoire simple	4
L'échantillonnage stratifié :	5
Phase 3 : comparaison des résultats selon méthodes d'échantillonnage	8
Conclusion	9
Partie 2 : Traitement de données d'enquête	9
Introduction	9
Explication du code R	10
Conclusion partie 2	12
Conclusion	12
Code R	12
Partie 1 :	12
Partie 2 :	18

Introduction

Ce projet a pour objectif d'appréhender l'incertitude et la précision de l'estimation d'une grandeur mesurable dans une population à l'aide d'intervalle de confiance réalisé par un processus d'échantillonnage. Pour cette étude, nous avons examiné la population de la région Grand-Est. Pour cela, le travail a été réalisé en deux temps sur le logiciel R, par l'intermédiaire d'un sondage aléatoire simple à probabilités égales, puis par l'intermédiaire d'un échantillon par strates.

La deuxième partie du projet consiste, sur un autre jeu de données, de trouver des relations significatives entre la variable « sport » et plusieurs autres variables qualitatives à l'aide du test de khi deux d'indépendance.

Partie 1 : Estimation du nombre d'habitants d'une région de France

Contexte

Un échantillonnage est un tirage de plusieurs effectifs à partir d'une population dans le but d'en créer des estimations généralisables sur la population totale. Il est utilisé pour limiter les coûts et augmenter la rapidité d'apparition des résultats. L'enjeu est alors de comprendre la structure de la population avant de générer ses estimations pour en garantir la cohérence selon un risque défini. A travers cet exercice, on testera l'échantillonnage sous 2 méthodes en vue d'analyser leurs pertinences sur notre population des communes du Grand-est.

Phase 0 : préparation du jeu de données

```
## chargement des données
#install.packages("sampling") # installer la librairie d'échantillonnage
library(sampling)

if (file.exists("population_francaise_communes.csv")){
  donnees <- read.csv("population_francaise_communes.csv",header = TRUE,)
  print("Données des communes importées avec succès")
} else {print("Le fichier (population_francaise_communes.csv) n'existe pas encore, il va être généré à

  if (file.exists("population_francaise_communes.xlsx")){
    #install.packages("readxl") # installer la librairie permettant de lire de fichiers au format exce
    library("readxl")

    ## Data frame donnees avec les valeurs de la base
    donnees_brutes <- read_excel("population_francaise_communes.xlsx", sheet = "Communes")
    donnees <- na.omit(donnees_brutes)
    donnees <- donnees[,c(2,3,7,10)] #sélection des colonnes d'intérêt (région, code département, comm
    #les communes sélectionnées, leur département et leur nombre d'habitants
    colnames(donnees) <- as.character(donnees[1, ]) # création d'entête
    donnees <- donnees[-1, ] #suppression de la 1ere ligne afin de supprimer les titres

    write.csv(donnees, "population_francaise_communes.csv",row.names = FALSE)
  } else{
    print("Le fichier 'population_francaise_communes.xlsx' n'existe pas dans le dossier.")
  }
  print("IMPORTER le fichier manquant (population_francaise_communes.xlsx) puis réexecuter le code")
}
```

Cette partie certifie que le code fonctionnera pour l'utilisateur final par la vérification de présence des fichiers nécessaires et indication dans le cas contraire. Ensuite nous pouvons sélectionner le jeu d'intérêt sur le critère « region », Communes du « Grand Est » dans notre cas, pour en faire un état des lieux.

```
donnees = donnees[donnees$Nom.de.la.région== region,c("Code.département","Commune","Population.totale")]
```

Phase 1 : vision globale

On apprend grâce aux lignes suivantes que la région « Grand-est » et ses 5121 communes compte au total 5 668 492 Habitants, c'est le chiffre que nos estimations doivent approcher.

```
#### PHASE 1; vision globale
str(donnees) # révéler la structure du jeu de données
head(donnees) # montrer l'allure des 6 premières lignes

## Variable U avec les communes
U = donnees$Commune
head(U)

## Nb de communes dans U
N = length(U)

## Nb d'habitants en france
T = sum(donnees$Population.totale)
```

Phase 2 : calculer des valeurs

L'échantillonnage aléatoire simple

Le programme principal permet de :

1. Tirer notre échantillon E (100 communes celles de la région)
2. Faire un état des lieux de la structure de l'échantillon
3. Calculer le nombre moyen d'habitants de E et l'IDC à 95% du nombre moyen d'habitants μ par commune
4. Dédire une estimation « Test » du nombre habitants total T et son intervalle de confiance (IDC).
5. Calculer la marge d'erreur

```
## Tirage aleatoire simple d'un echantillon de taille n=100
n=100
E=sample(U, n)
head(E)

## toutes les données des 100 communes
donnees1= donnees[donnees$Commune %in% E, ]
head(donnees1)

## moyenne echantillon
xbar= mean(donnees1$Population.totale)
xbar

## idc mu
idcmoy = t.test(donnees1$Population.totale)$conf.int
idcmoy

## nb habitant estimé
T_est = N*xbar
T_est

## idc de T
idcT = idcmoy*N
idcT
b_inf = idcT[1]
b_sup = idcT[2]

## marge d'erreur
marge=(idcT[2]-idcT[1])/2
marge
```

Répéter l'opération permet de faire ressortir des moyennes et avoir une idée de la stabilité de notre méthode. Pour ce faire et gagner du temps, on crée une boucle autour de ce programme en initialisant un data frame vide afin de pouvoir y stocker les valeurs pour chaque échantillon.

```
## Initialisation des résultats pour pouvoir les sauvegarder ensuite
resultats = data.frame(pop_exact = numeric(), pop_est = numeric(), marge = numeric())

n_echantillons = 10 ## nombre de répétition de l'échantillonnage
for (i in 1:n_echantillons) { #10 fois
```

Après initialisation de la boucle, on sauvegarde et export les données dans un fichier CSV, qui nous servira à faire des graphiques (que vous verrez plus tard au moment des comparaisons).

```
    new_row=data.frame(pop_exact = T, pop_est = T_est, marge = marge, IDC_Borne_inf = b_inf, IDC_Borne_sup= b_sup)
    resultats = rbind(resultats,new_row)
  }
write.csv2(resultats,"resultats.csv",row.names=FALSE)
```

À la suite de la création graphique, on remarque une grande variation des marges selon l'échantillon, on est tenté de relever les caractéristiques de la population afin de mieux estimer ses chiffres sans varier autant => on veut stabiliser nos résultats, pour ce faire on va passer par la stratification et pondération des sous-groupes.

L'échantillonnage stratifié :

Les objectifs sont les mêmes que le programme précédant mais en ajoutant des strates. Pour comparer les méthodes de stratification, nous avons créé une logique permettant d'exécuter le programme stratifié par quantiles ou une version plus adaptée (améliorée) à notre jeu de données. Nous en avons défini 5, selon des bornes fixes et non exactement des quantiles car avec notre population cela rendait des résultats plus mauvais que l'aléatoire comme vous le verrez dans la partie comparaison.

```

version_amelioree = TRUE # Proposition pour améliorer
if (version_amelioree == TRUE){
  # infos quantiles, etc...
  summary(donnees$Population.totale) # nous indique

# — Strates —————
# Seuils : 0 | 100 | 500 | 2000 | 10000 | +Inf

```

Summary permet de rendre compte d'un phénomène qui a beaucoup d'incidence sur la suite : la majorité des communes ont peu d'habitant mais (moyenne > médiane) mais des valeurs tirent vers l'extrême haut.

Bornes selon quantiles

Création dynamique des strates ; on fait ressortir les quantiles qu'on utilise comme bornes : [0 : 134[[134 : 306[[306 : 738[[738 : 293 538]

```

#calculer les quantiles
Pop_quantiles = quantile(donnees$Population.totale, probs = seq(0, 1, 1/4))
q1 = as.integer(Pop_quantiles[2])
q2 = as.integer(Pop_quantiles[3])
q3 = as.integer(Pop_quantiles[4])

donnees$strate <- cut(
  donnees$Population.totale,
  breaks = c(0,q1,q2,q3, Inf),
  labels = c(1, 2, 3, 4),
  include.lowest = TRUE # inclut les 0 dans la strate 1
)

```

Q1 = 134, Q2 = 306,
Q3 = 738

On utilise les quantiles alors les nb de tirages par strate sont égaux (25) et on peut alors créer les strates :

```

# — Tirage stratifié (avec remise dans chaque strate) —————
st <- strata(data, stratanames = "strate", size = nh, method = "srswr")
data1 <- getdata(data, st)

```

Une fois l'échantillon tiré, on peut calculer les moyennes et variance par strate, pour cela on crée une liste sauvegardant toutes les valeurs

```

# — Moyennes et variances par strate —————
mh <- sapply(ech, function(e) mean(e$Population.totale))
varh <- sapply(ech, function(e) {
  if (nrow(e) <= 1) 0 else var(e$Population.totale)
})

```

On se rend compte que les variances suivent presque une loi puissance longuement étalée comme le montre cette observation sur un échantillon 8.281567e+02 2.676167e+03 1.630146e+04 4.979745e+07

On ajoute d'autres estimateurs et regardons leurs résultats

```

# — Estimateur de la moyenne stratifiée —————
Xbarst <- sum(Nh * mh) / N

# — Variance estimée de Xbarst —————
# Avec correction de population finie : (1 - fh)
varXbarst <- sum((gh^2) * (1 - fh) * varh / nh)

# — Estimation du total et marge d'erreur (IC 95 %)
T_est <- N * Xbarst
marge <- N * 1.96 * sqrt(varXbarst)

```

```

> Xbarst
[1] 1092.706
> varXbarst
[1] 122062.8
> T_est
[1] 5595745
> marge
[1] 3506731

```

pop_exact	pop_est	marge	Borne_inf	Borne_sup
5 668 492,00	3 680 994,88	2 110 209,58	1 570 785,30	5 791 204,46
5 668 492,00	7 105 588,32	6 389 026,78	716 561,54	13 494 615,10
5 668 492,00	3 547 367,91	928 868,64	2 618 499,27	4 476 236,55
5 668 492,00	4 342 854,20	1 459 570,24	2 883 283,96	5 802 424,44
5 668 492,00	6 117 921,80	4 400 478,48	1 717 443,32	10 518 400,29
5 668 492,00	3 972 189,00	1 319 032,63	2 653 156,37	5 291 221,63
5 668 492,00	5 303 014,97	2 081 018,97	3 221 996,00	7 384 033,94
5 668 492,00	3 708 096,40	964 509,33	2 743 587,08	4 672 605,73
5 668 492,00	4 195 554,97	1 260 462,59	2 935 092,38	5 456 017,56
5 668 492,00	6 327 666,70	2 656 671,92	3 670 994,78	8 984 338,62

On a aussi fait une boucle en amont avec le même principe de sauvegarde à chaque échantillon et on obtient alors notre tableau dans Excel. Les résultats nous ont donné envie d'essayer une autre stratification pour essayer d'atteindre la population totale de plus proche.

Bornes adaptées après étude sous Excel

On crée nos propres strates

```
donnees$strate <- cut(
  donnees$Population.totale,
  breaks = c(0, 100, 500, 2000, 10000, Inf),
  labels = c(1, 2, 3, 4, 5),
  include.lowest = TRUE # inclut les 0 dans la strate 1
)
```

On regarde les répartitions puis initialise l'espace de sauvegarde des données

```
table(donnees$strate)
```

```
# — Initialisation —————
resultats_strat <- data.frame(
  pop_exact = numeric(),
  pop_est   = numeric(),
  marge     = numeric())
```




Le reste sur les calculs d'indice est la même chose que pour le stratifié en quartiles. Finalement on sauvegarde dans un nouveau fichier nommé resultat_strat5.csv.

```
write.csv2(resultats_strat, "resultats_strat5.csv", row.names = FALSE)
```

Analyse :

La population étudiée est hétérogène car les estimations stratifiées donnent de meilleurs résultats (variation de marge inter échantillons plus faible). La limite se trouve dans le nombre de tirages ; face à notre population où moins de **2%** des communes représentent plus de **35% de la taille totale**, en ne tirant que 100 communes, on expose la strate 6 (entre 20 000 et plus) qui permettrait de séparer les très grandes communes des autres, à une représentativité très faible (0,0014) et donc on sort toutes ces grosses communes de l'échantillonnage => estimation alors jamais représentative. Notre choix a donc été de **regrouper toutes les communes de plus de 10 000** habitants afin d'inclure toutes les communes quitte à avoir des variances plus élevées.

Phase 3 : comparaison des résultats selon méthodes d'échantillonnage



Remarques :

1. Les résultats des échantillonnages stratifiés permettent de stabiliser la variation de marge
2. L'échantillonnage stratifié selon les quartiles sous-estime systématiquement la taille d'habitants
3. Allures semblables des estimations entre échantillonnage aléatoire simple et l'échantillonnage stratifié à 5 strates

Conclusion

Théoriquement, la méthode stratifiée est plus précise : en effet avec sa marge dont les oscillations sont plus faibles prouve que le modèle est plus stable. En prenant en compte les caractéristiques de la population, on affine nos estimations, ici c'est passé par la segmentation de nos communes par des strates adaptées à notre jeu de données à la suite d'analyses sur Excel. On retient aussi que la population était très disparate car **moins de 4% des communes retiennent 50% de la totalité des habitants** ; ce qui était compliqué à retranscrire alors avec précision sur un échantillon d'**uniquement 100 communes**, car ces communes ont des tailles de 5 177 à 293 538 habitants, alors la pioche est quasiment assimilable à de l'aléatoire car la représentativité de cette tranche est minime mais son importance dans le résultat finale est énorme ce qui explique que la **similarité de résultats trouvés entre échantillonnage aléatoire et le stratifié**.

Partie 2 : Traitement de données d'enquête

Introduction

Dans cette partie, nous avons importé et exploré les données du fichier « EnqueteSportEtudiant2024.csv » afin de comprendre la structure des variables et des individus étudiés.

Nous avons ensuite réalisé des tableaux croisés entre la variable « sport » et plusieurs variables (département, niveau, sexe, logement et bourse) après avoir nettoyé les données.

Enfin, nous avons appliqué le test du khi-deux puis calculé le V de Cramer pour les relations significatives afin d'analyser l'existence et l'intensité des liens entre les variables.

Afin d'alléger la structure du rapport, nous avons illustré les explications du code avec un seul exemple de croisement de variables. Cette même méthode a ensuite été répétée pour chacune des variables choisies.

Explication du code R

```
> head(sport)
  sexe deptgeo deptgeo_Autre deptformation niveau reprise alternant bourse travail logement logement_Autre fumer
1 Un homme      85                HSE      BUT1      Non      Oui                Non      Non      NA      Non
2 Un homme      79                GEA      BUT3      Non      Oui                Non      Non      NA      Non
3 Un homme  Autre      49                HSE Licence Pro      Non      Oui                Non      Non      NA      Non
4 Un homme  Autre      76                HSE Licence Pro      Non      Oui                Non      Non      NA      Non
5 Un homme  Autre      33                SD      BUT1      Non      Non                Non      Non      NA      Non
6 Un homme      16                GEA      BUT3      Non      Oui                Non      Non      NA      Non

# IMPORTATION DES DONNEES
sport<- read.csv2("EnqueteSportEtudiant2024.csv")

# AFFICHAGE des 6 premières lignes de la table et EXPLORATION des données
head(sport)
str(sport)
summary(sport)
```

Dans cette partie, nous importons les données du fichiers csv « EnqueteSportEtudiant2024.csv » afin de pouvoir analyser les variables. Nous affichons par la suite les 6 premières lignes de chacune de nos variables ainsi que sa structure et les caractéristiques de chacune des variables afin de comprendre son organisation.

```
# Département de formation :
# filtrage des données : on recupère les lignes de données non nulles
sport_dept <- subset(sport, !is.na(deptformation) & !is.na(sport) & sport != "" & deptformation != "")
TCD_departement <- table(sport_dept$deptformation, sport_dept$sport)
TCD_departement
```

Par la suite, nous avons construit des tableaux croisés de la variable « sport » et de 5 autres variables quantitatives : département de formation, niveau de formation, sexe, logement, bourse. Pour chacun des tableaux nous avons au préalable filtrer les données afin de n'utiliser que les lignes de données non nulles et exclure les modalités comportant un nombre insuffisant de données.

```
# TEST KHI 2, EFFECTIFS THEORIQUES, CONTRIBUTIONS et RESIDUS
```

```
# departement de formation :
khideux_departement= chisq.test(TCD_departement)
khideux_departement
khideux_departement$expected      #effectifs théoriques
khideux_departement$residuals     #contributions
khideux_departement$residuals^2   #résidus
```

Ensuite, nous avons mis en place le test d'indépendance du khi deux à partir des tableaux croisés réalisé au préalable. Nous avons également affiché les affectifs théoriques de chaque test de khi deux afin de vérifier les conditions d'utilisation de ce dernier. Les contributions et les résidus sont aussi affiché dans le programme, afin d'obtenir la p-valeur pour interpréter la valeur : est-elle significative ? Elles sont significatives dans le cas où la p-valeur est inférieur à 0,05. Plus la valeur de p

est petite, plus la probabilité de commettre une erreur en rejetant l'hypothèse nulle est faible.

	Variable	P_valeur	
1	Département de formation	0.0004795557	Significatif
2	Niveau de formation	0.0431137000	Significatif
3	Sexe	0.0002651427	Significatif
4	Logement	0.2155747337	Non significatif
5	Bourse	0.1702387583	Non significatif

Résultats p-valeur :

```
# département de formation :
n <- dim(sport)[1]
p <- nrow(TCD_département)
q <- ncol(TCD_département)
m <- min(p-1, q-1)
V_département =sqrt(khideux_département$statistic/(n*m))
V_département
```

Puis, nous avons calculer le V de Cramer pour chaque test significatif. Le V de cramer sert à savoir si le lien est fort.

	Variable	P_valeur	V_Cramer
1	Département de formation	0.0004795557	0.2019
2	Niveau de formation	0.0431137000	0.1474
3	Sexe	0.0002651427	0.1883

Tableau récapitulatif :

Parmi cinq croisements de variables, trois sont significatives et permettent de voir que les liens sont :

- Acceptable pour les variables sport et départements de formations
- Limite acceptable pour les variables sport et sexe
- Limite acceptable pour les variables sport et niveau de formation

On observe que plus le V de Cramer est élevé, plus la relation entre les deux variables sont fortes. La liaison la plus forte est celle de la variable département de formation avec la variable sport, on trouve une valeur d'environ 0.2019, elle est donc acceptable car elle se situe au-dessus de 0.20.

Conclusion partie 2

Cette SAE nous a permis d'apprendre à travailler sur des données réelles en passant par plusieurs étapes : importation, exploration, nettoyage et analyse statistique. Nous avons utilisé des tableaux croisés, le test du khi-deux et le V de Cramer afin d'interpréter les résultats obtenus. Ce travail nous a montré l'importance de vérifier et préparer les données pour obtenir des analyses fiables et cohérentes.

Conclusion

Les méthodes statistiques permettent de modéliser des résultats, de prévoir et rendre compte d'une situation. Ces 2 exercices ont permis d'aborder l'importance de la compréhension de la population et ses caractéristiques pour générer des estimations cohérentes avec la réalité ; le second nous a permis de travailler à la fois le nettoyage afin de dégager de réelles interprétations cohérentes et montrer la force des statistiques dans un volume large de données pour révéler les croisements les plus intéressants.

Code R

Partie 1 :

```
#localisation des fichiers

setwd("C:/Users/Utilisateur/Desktop/R_Grand_est")

### PHASE 0 ; préparation des données et import des librairies utiles

## chargement des données

#install.packages("sampling") # installer la librairie d'échantillonnage

library(sampling)

if (file.exists("population_francaise_communes.csv")){

  donnees <- read.csv("population_francaise_communes.csv",header = TRUE,)

  print("Données des communes importées avec succès")

} else {print("Le fichier (population_francaise_communes.csv) n'existe pas encore, il va être généré à partir du fichier
population_francaise_communes.xlsx")}

if (file.exists("population_francaise_communes.xlsx")){

  #install.packages("readxl") # installer la librairie permettant de lire de fichiers au format excel

  library("readxl")

  ## Data frame donnees avec les valeurs de la base

  donnees_brutes <- read_excel("population_francaise_communes.xlsx", sheet = "Communes")

  donnees <- na.omit(donnees_brutes)
```

```

donnees <- donnees[,c(2,3,7,10)] #sélection des colonnes d'intérêt (région, code département, commune,
population totale)

#les communes sélectionnées, leur département et leur nombre d'habitants

colnames(donnees) <- as.character(donnees[1, ]) # création d'entête

donnees <- donnees[-1, ] #suppression de la 1ere ligne afin de supprimer les titres

write.csv(donnees, "population_francaise_communes.csv",row.names = FALSE)

} else{

  print("Le fichier 'population_francaise_communes.xlsx' n'existe pas dans le dossier.")

}

print("IMPORTER le fichier manquant (population_francaise_communes.xlsx) puis réexécuter le code")

}

#### Phase 0 BIS : n'avoir que le jeu de données sur la zone géographique d'intérêt

regions = unique(donnees$Nom.de.la.région) #liste toutes les régions existants

regions # liste les régions pour copier le nom de la région sans faute d'orthographe et de l'insérer à la ligne suivante

region = "Grand Est"

donnees = donnees[donnees$Nom.de.la.région== region,c("Code.département","Commune","Population.totale")]

write.csv2(donnees,paste(region,".csv"),row.names=FALSE) #sauvegarde sur l'ordinateur les données triées pour la
régions d'intérêt

#### PHASE 1; vision globale

str(donnees) # révéler la structure du jeu de données

head(donnees) # montrer l'allure des 6 premières lignes

## Variable U avec les communes

U = donnees$Commune

head(U)

## Nb de communes dans U

N = length(U)

## Nb d'habitants en france

T = sum(donnees$Population.totale)

#### Phase 2 : calculer des valeurs

n_echantillons = 10 ## nombre de répétition de l'échantillonnage

##### Echantillonnage aléatoire simple

## Initialisation des résultats pour pouvoir les sauvegarder ensuite

resultats = data.frame(pop_exact = numeric(),pop_est = numeric(), marge = numeric())

for (i in 1:n_echantillons) { #10 fois

```

```

## Tirage aleatoire simple d'un echantillon de taille n=100

n=100

E=sample(U, n)

head(E)

## toutes les données des 100 communes

donnees1= donnees[donnees$Commune %in% E, ]

head(donnees1)

## moyenne echantillon

xbar= mean(donnees1$Population.totale)

xbar

## idc mu

idcmoy = t.test(donnees1$Population.totale)$conf.int

idcmoy

## nb habitant estimé

T_est = N*xbar

T_est

## idc de T

idcT = idcmoy*N

idcT

b_inf = idcT[1]

b_sup = idcT[2]

## marge d'erreur

marge=(idcT[2]-idcT[1])/2

marge

new_row=data.frame(pop_exact = T, pop_est = T_est, marge = marge, IDC_Borne_inf = b_inf, IDC_Borne_sup= b_sup)

resultats = rbind(resultats,new_row)}

write.csv2(resultats,"resultats.csv",row.names=FALSE)

#print(resultats)

moy_est = sum(resultats$pop_est)/n_echantillons

ratio = paste(as.character(round((moy_est/T)-1,2)*100),"% entre Réalité et estimation moyenne")

ratio

##### Stratifié #####

version_amelioree = TRUE # Proposition pour améliorer la précision, utilisation d'autres quantiles déterminés par
analyse des données sur excel ; Initialement faux pour suivre les consignes de l'exercice

if (version_amelioree == TRUE){

  # infos quantiles, etc...

  summary(donnees$Population.totale) # nous indique que la majorité des communes ont peu d'habitant mais
(moyenne > mediane) des valeurs tirent vers l'extrême

```

```

# — Strates —————

# Seuils : 0 | 100 | 500 | 2000 | 10000 | +Inf

donnees$strate <- cut(
  donnees$Population.totale,
  breaks = c(0, 100, 500, 2000, 10000, Inf),
  labels = c(1, 2, 3, 4, 5),
  include.lowest = TRUE # inclut les 0 dans la strate 1 )
datastrat <- donnees[, c("Commune", "Population.totale", "strate")]

# — Population exacte (pour vérification) —————

T_exact <- sum(donnees$Population.totale)

table(donnees$strate)

# — Initialisation —————

resultats_strat <- data.frame(
  pop_exact = numeric(),
  pop_est = numeric(),
  marge = numeric())

for (i in 1:n_echantillons) {
  data <- datastrat[order(datastrat$strate), ] #lisibilité simplifiée : jeu ordonné par nb habitants
  # Effectifs des strates

  Nh <- table(data$strate) # vecteur de longueur 5
  N <- sum(Nh)

  # Poids des strates

  gh <- Nh / N

  # — Allocation des 100 tirages —————

  n <- 100

  nh <- round(gh,2)*100

  # Taux de sondage par strate

  fh <- nh / Nh

  fh

  # — Tirage stratifié (avec remise dans chaque strate) —————

  st <- strata(data, stratanames = "strate", size = nh, method = "srswr")

  data1 <- getdata(data, st)

  # — Sous-échantillons par strate —————

  ech <- lapply(1:5, function(h) data1[data1$strate == h, ])

  # — Moyennes et variances par strate —————

  mh <- sapply(ech, function(e) mean(e$Population.totale))

```

```

varh <- sapply(ech, function(e) {
  if (nrow(e) <= 1) 0 else var(e$Population.totale)
})

# — Estimateur de la moyenne stratifiée —————
Xbarst <- sum(Nh * mh) / N

# — Variance estimée de Xbarst —————
# Correction de population finie : (1 - fh)
varXbarst <- sum((gh^2) * (1 - fh) * varh / nh)

# — Estimation du total et marge d'erreur (IC 95 %) —————
T_est <- N * Xbarst

marge <- N * 1.96 * sqrt(varXbarst)

new_row <- data.frame(
  pop_exact = T_exact,
  pop_est = round(T_est),
  marge = round(marge), )

resultats_strat <- rbind(resultats_strat, new_row) } #print(resultats_strat)

moy_est_strat = sum(resultats_strat$pop_est)/n_echantillons
ratio_strat = paste(as.character(round((moy_est_strat/T)-1,2)*100),"%")
write.csv2(resultats_strat, "resultats_strat5.csv", row.names = FALSE)
}else{

print("Exécution du programme simple à 4 strates en quartiles")

#calculer les quartiles

Pop_quantiles = quantile(donnees$Population.totale, probs = seq(0, 1, 1/4)) #création de liste des 4 quantiles
q1 = as.integer(Pop_quantiles[2])
q2 = as.integer(Pop_quantiles[3])
q3 = as.integer(Pop_quantiles[4])

donnees$strate <- cut(
  donnees$Population.totale,
  breaks = c(0,q1,q2,q3, Inf),
  labels = c(1, 2, 3, 4),
  include.lowest = TRUE # inclut les 0 dans la strate 1 )

datastrat <- donnees[, c("Commune", "Population.totale", "strate")]

# — Population exacte (pour vérification) —————
T_exact <- sum(donnees$Population.totale)

# — Initialisation —————

resultats_strat <- data.frame(

```



```

pop_exact = numeric(),
pop_est  = numeric(),
marge    = numeric())
for (i in 1:n_echantillons) {
  data <- datastrat[order(datastrat$strate), ]

  # Effectifs des strates

  Nh <- table(data$strate) # vecteur de longueur 6
  N <- sum(Nh)

  # Poids des strates

  gh <- Nh / N

  # — Allocation des 100 tirages —————

  n <- 100

  nh <- c(25,25,25,25)

  # Taux de sondage par strate

  fh <- nh / Nh

  # — Tirage stratifié (avec remise dans chaque strate) —————

  st <- strata(data, stratanames = "strate", size = nh, method = "srswr")

  data1 <- getdata(data, st)

  # — Sous-échantillons par strate —————

  ech <- lapply(1:4, function(h) data1[data1$strate == h, ])

  # — Moyennes et variances par strate —————

  mh <- sapply(ech, function(e) mean(e$Population.totale))

  varh <- sapply(ech, function(e) {
    if (nrow(e) <= 1) 0 else var(e$Population.totale)
  })

  # — Estimateur de la moyenne stratifiée —————

  Xbarst <- sum(Nh * mh) / N

  # — Variance estimée de Xbarst —————

  # Avec correction de population finie : (1 - fh)

  varXbarst <- sum((gh^2) * (1 - fh) * varh / nh)

  # — Estimation du total et marge d'erreur (IC 95 %) —————

  T_est <- N * Xbarst

  marge <- N * 1.96 * sqrt(varXbarst)

  new_row <- data.frame(
    pop_exact = T_exact,
    pop_est  = round(T_est),

```

```

    marge = round(marge)
  )
  resultats_strat <- rbind(resultats_strat, new_row)}
#print(resultats_strat)
write.csv2(resultats_strat, "resultats_strates4.csv", row.names = FALSE)}

```

Partie 2 :

IMPORTATION DES DONNEES

```
sport<- read.csv2("EnqueteSportEtudiant2024.csv")
```

AFFICHAGE des 6 premières lignes de la table et EXPLORATION des données

```
head(sport)
```

```
str(sport)
```

```
summary(sport)
```

#VARIABLES CHOISIES : sport avec : département de formation - niveau de formation - sexe - logement - bourse

#TABLEAUX CROISES :

Département de formation :

filtrage des données : on recupère les lignes de données non nulles

```
sport_dept <- subset(sport, !is.na(deptformation) & !is.na(sport) & sport != "" & deptformation != "")
```

```
TCD_departement <- table(sport_dept$deptformation, sport_dept$sport)
```

```
TCD_departement
```

Niveau de formation :

filtrage des données : on recupère les lignes de données non nulles

```
sport_niv <- subset(sport, !is.na(niveau) & !is.na(sport) & sport != "" & niveau != "")
```

```
TCD_niveau <- table(sport_niv$niveau, sport_niv$sport)
```

```
TCD_niveau
```

Sexe :

filtrage des données : on recupère les lignes de données non nulles

```
sport_sexe <- subset(sport, !is.na(sexe) & !is.na(sport) & sport != "" & sexe != "")
```

```
TCD_sexe <- table(sport_sexe$sexe, sport_sexe$sport)
```

```
TCD_sexe
```

```
# Logement :
```

```
# filtrage des données : on recupère les lignes de données non nulles
```

```
sport_log <- subset(sport, !is.na(logement) & !is.na(sport) & sport != "" & logement != "" & logement != "Autre")
```

```
TCD_logement <- table(sport_log$logement, sport_log$sport)
```

```
TCD_logement
```

```
# bourse :
```

```
# filtrage des données : on recupère les lignes de données non nulles
```

```
sport_bourse <- subset(sport, !is.na(bourse) & !is.na(sport) & sport != "" & bourse != "")
```

```
TCD_bourse <- table(sport_bourse$bourse, sport_bourse$sport)
```

```
TCD_bourse
```

```
# TEST KHI 2, EFFECTIFS THEORIQUES, CONTRIBUTIONS et RESIDUS
```

```
# departement de formation :
```

```
khideux_departement= chisq.test(TCD_departement)
```

```
khideux_departement
```

```
khideux_departement$expected    #effectifs théoriques
```

```
khideux_departement$residuals   #contributions
```

```
khideux_departement$residuals^2 #résidus
```

```
# niveau de formation :
```

```
khideux_niveau= chisq.test(TCD_niveau)
```

```
khideux_niveau
```

```
khideux_niveau$expected
```

```
khideux_niveau$residuals
```

```
khideux_niveau$residuals^2
```

```
# sexe :
```

```
khideux_sexe= chisq.test(TCD_sexe)
```

```
khideux_sexe
```

```
khideux_sexe$expected
```

```
khideux_sexe$residuals
```

```
khideux_sexe$residuals^2
```

```

# logement :

khideux_logement= chisq.test(TCD_logement)

khideux_logement

khideux_logement$expected

khideux_logement$residuals

khideux_logement$residuals^2


# bourse :

khideux_bourse= chisq.test(TCD_bourse)

khideux_bourse

khideux_bourse$expected

khideux_bourse$residuals

khideux_bourse$residuals^2


# V DE CRAMER

# département de formation :

n <-dim(sport)[1]

p <- nrow(TCD_departement)

q <- ncol(TCD_departement)

m <- min(p-1, q-1)

V_departement =sqrt(khideux_departement$statistic/(n*m))

V_departement


# niveau de formation :

n <-dim(sport)[1]

p <- nrow(TCD_niveau)

q <- ncol(TCD_niveau)

m <- min(p-1, q-1)

V_niveau =sqrt(khideux_niveau$statistic/(n*m))

V_niveau


# sexe :

n <-dim(sport)[1]

```

```
p <- nrow(TCD_sexe)
q <- ncol(TCD_sexe)
m <- min(p-1, q-1)
V_sexe = sqrt(khideux_sexe$statistic/(n*m))
V_sexe
```

```
# Création du tableau récapitulatif
```

```
# Tableau récapitulatif
```

```
tableau_recap <- data.frame(Variable = c("Département de formation", "Niveau de formation", "Sexe"),
```

```
  P_valeur = c(khideux_departement$p.value, khideux_niveau$p.value, khideux_sexe$p.value),
```

```
  V_Cramer = c(round(V_departement, 4), round(V_niveau, 4), round(V_sexe, 4)))
```

```
# Affichage
```

```
tableau_recap
```